



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ» (ИУ)

КАФЕДРА «ПРОГРАММНОЕ ОБЕСПЕЧЕНИЕ ЭВМ И ИНФОРМАЦИОННЫЕ ТЕХНОЛОГИИ» (ИУ7)

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ
НА ТЕМУ:

Методы балансировки высоконагруженных систем

Студент	ИУ7-54Б	_____ Булдаков М.
Студент	ИУ7-54Б	_____ Турчанский Н. А.
Студент	ИУ7-54Б	_____ Рунов К. А.
Студент	ИУ7-54Б	_____ Козлитин М. А.
Руководитель		_____ Кострицкий А. С.

2023 г.

СОДЕРЖАНИЕ

ОПРЕДЕЛЕНИЯ	3
ВВЕДЕНИЕ	4
1 Аналитический раздел	5
1.1 Постановка задачи	5
1.2 Алгоритмы решения задачи балансировки	6
1.3 Статическая балансировка	6
1.3.1 Алгоритмы на основе хеширования	6
1.3.2 Алгоритмы циклического перебора	8
1.4 Динамическая балансировка	9
1.4.1 Алгоритм динамического циклического перебора	10
1.4.2 Алгоритмы наименьших соединений	11
1.4.3 Алгоритм наименьшего времени ответа	12
1.4.4 Алгоритм фиксированных весов	13
1.4.5 Алгоритм 2 (N) случайных выборов	14
1.4.6 Алгоритм на основе ресурсов	15
ЗАКЛЮЧЕНИЕ	17
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	20

ОПРЕДЕЛЕНИЯ

В настоящей расчетно-пояснительной записке применяют следующие термины с соответствующими определениями.

Вычислительный узел (узел) — устройство, выполняющее основную логику обработки запроса [1].

Хеш-таблица — структура данных для реализации ассоциативных массивов [2].

NAT — Network Address Translation, метод трансляции сетевых адресов [3].

IP-адрес — уникальный адрес, идентифицирующий устройство в интернете или локальной сети [4].

URL-адрес — Uniform Resource Locator, адрес, который выдан уникальному ресурсу в интернете [5].

ВВЕДЕНИЕ

В современном мире люди часто используют интернет для взаимодействия с приложениями. Сетевые приложения востребованы как обычными пользователями, так и крупными корпорациями, проводящими сложные вычисления и обмен данными. Одной из задач, с которыми сталкиваются интернет-компании, является обеспечение бесперебойного доступа к предоставляемым интернет-ресурсам [6].

За последние 5 лет количество пользователей в интернете выросло на 30 процентов, что привело к резкому увеличению нагрузки на многие системы [7]. Обработка выросшей нагрузки и обеспечение бесперебойного доступа к интернет-ресурсам, требует добавления в систему новых вычислительных узлов, для эффективной работы которых, необходимо осуществлять балансировку нагрузки [1; 8—10].

Балансировка нагрузки — это механизм приблизительного выравнивания рабочей нагрузки между всеми узлами системы [9; 11].

Целью данной работы является описание методов балансировки нагрузки в высоконагруженных системах.

Для достижения поставленной цели необходимо выполнить следующие задачи:

- описать основные подходы к решению задачи балансировки нагрузки;
- сформулировать критерии сравнения методов решения задачи балансировки нагрузки;
- классифицировать методы решения задачи балансировки нагрузки.

1 Аналитический раздел

С ростом числа запросов к системе, встает вопрос о ее масштабировании. Масштабирование — это процесс роста системы со временем, для эффективной обработки все большего и большего количества запросов в единицу времени [12]. Выделяют два вида масштабирования: горизонтальное и вертикальное [1; 10; 13]. Вертикальное масштабирование происходит за счет увеличения мощности вычислительного узла. Горизонтальное масштабирование, заключается в добавлении новых вычислительных узлов, выполняющих одинаковые функции. Для расширения возможностей горизонтального масштабирования используются балансировщики нагрузки [10; 13].

Балансировщик нагрузки — это программа, принимающая весь входящий трафик запросов и распределяющая его между несколькими вычислительными узлами с целью оптимизации использования ресурсов, сокращения времени обслуживания запросов, а также обеспечения отказоустойчивости [13].

1.1 Постановка задачи

Постановка задачи балансировки нагрузки формулируется следующим образом: имеется множество, состоящее из n запросов, которое должно быть обслужено M узлами. Каждый узел может обслуживать не более одного запроса в каждый момент времени. Каждый запрос обслуживается не более, чем одним узлом в каждый момент времени, а процесс обслуживания запроса не может быть прерван.

Под расписанием понимается функция, которая каждому узлу l и моменту времени t сопоставляет запрос, обслуживаемый узлом l в момент времени t , либо указывает, что узел l в момент t простаивает. Каждому запросу i сопоставлена неубывающая функция штрафа $\phi_i(t)$. В качестве такой функции может быть выбрана функция $\phi_i(t) = t$. Тогда решением задачи балансировки нагрузки является составление расписания s , которое минимизирует выражение (1.1) [9].

$$F_{max} = \max_{i \in n} \{\phi_i(t_i(s))\}, \quad (1.1)$$

где $t_i(s)$ — момент завершения обслуживания запроса i при расписании s .

1.2 Алгоритмы решения задачи балансировки

Балансировщик нагрузки работает по одному из алгоритмов, решающих задачу балансировки. На вход этому алгоритму подаются набор запросов, приходящих в систему и набор вычислительных узлов, которыми система располагает. Задача алгоритма сводится к минимизации времени обработки запросов за счет распределения запросов по вычислительным узлам.

Для анализа алгоритмов балансировки выделяют следующие критерии [1]:

- точность прогнозирования — степень соответствия расчетных результатов работы алгоритма их фактическому значению;
- отказоустойчивость — показатель устойчивости алгоритма к возникновению разнообразных ошибок;
- время обработки нового запроса — время от поступления нового запроса до его перенаправления к цели.

Методы балансировки условно разделяют на статические и динамические [1; 14; 15].

1.3 Статическая балансировка

Статическая балансировка — это метод распределения нагрузки на узлы, основанный на заранее определенных параметрах [1; 16].

К статическим алгоритмам балансировки относят алгоритмы на основе хеширования и алгоритмы циклического перебора (англ. Round Robin) [1; 10; 17—19].

1.3.1 Алгоритмы на основе хеширования

Алгоритмы балансировки нагрузки на основе хеширования работают по общему принципу, который состоит из следующих шагов:

- 1) из пришедшего запроса выбрать информацию (например, IP-адрес или URL-адрес), которая считается ключом хеш-функции в рамках данного алгоритма;

- 2) на основе ключа вычислить значение хеш-функции, которое соответствует идентификатору узла, на который следует перенаправить запрос для его обработки;
- 3) перенаправить запрос на узел, чей идентификатор был вычислен ранее.

Хеширование на основе IP-адреса

Алгоритм балансировки нагрузки «Хеширование на основе IP-адреса» работает по общему принципу методов балансировки нагрузки на основе хеширования. Ключом хеш-функции в данном алгоритме считается IP-адрес источника запроса [17; 18; 20]. Запросы, имеющие один и тот же IP-адрес, будут обслужены одним и тем же узлом. Если имеются запросы r_1, r_2 , узлы l_1, l_2 , моменты времени t_1, t_2 и функция расписания s , то, в соответствии с данным алгоритмом, будет выполнено следующее:

$$(\forall t_1, t_2) \left(\begin{cases} s(l_1, t_1) = r_1, \\ s(l_2, t_2) = r_2, \\ r_1.ip_address = r_2.ip_address. \end{cases} \Rightarrow l_1 = l_2 \right). \quad (1.2)$$

Особенности алгоритма «Хеширование на основе IP-адреса»:

- алгоритм гарантирует, что все запросы от одного и того же пользователя направляются на один и тот же сервер;
- алгоритм прогнозируемый;
- добавление новых серверов потребует лишь изменения хеш-функции для корректной работы алгоритма;
- неравномерная нагрузка на узел, если запросы начинают приходить из сети, использующей NAT, с большим количеством пользователей.

Хеширование на основе URL-адреса

Алгоритм балансировки нагрузки «Хеширование на основе URL-адреса» работает по общему принципу методов балансировки нагрузки на основе хеширования. Ключом хеш-функции в данном алгоритме считается URL-адрес, к которому обращается источник запроса [17; 19; 20]. Запросы к одному

и тому же URL-адресу, будут обслужены одним и тем же узлом. То есть, если имеются запросы r_1, r_2 , узлы l_1, l_2 , моменты времени t_1, t_2 и функция расписания s , то, в соответствии с данным алгоритмом, будет выполнено следующее:

$$(\forall t_1, t_2) \left(\begin{cases} s(l_1, t_1) = r_1, \\ s(l_2, t_2) = r_2, \\ r_1.url_address = r_2.url_address. \end{cases} \Rightarrow l_1 = l_2 \right) \quad (1.3)$$

Особенности алгоритма «Хеширование на основе URL-адреса»:

- алгоритм гарантирует, что все запросы к одному и тому же URL направляются на тот же сервер;
- алгоритм прогнозируемый;
- изменение структуры URL может потребовать перенастройки балансировщика;
- популярные URL могут создавать неравномерную нагрузку на узлы.

1.3.2 Алгоритмы циклического перебора

В алгоритмах циклического перебора каждый следующий запрос отправляется на новый вычислительный узел по заранее определенному порядку [13].

Алгоритмы циклического перебора работают по общему принципу. Если имеется N запросов и $nodes$ — массив, содержащий узлы, а M длина этого массива, то алгоритм состоит из следующих шагов:

- 1) создать переменную $i = 0$;
- 2) для каждого запроса из N :
 - отправить текущий запрос на i -й узел в массиве;
 - увеличить значение i ;
 - если $i \geq M$, то $i = 0$.

Особенности алгоритма равномерного распределения:

- алгоритм прогнозируемый;
- невозможно отследить вышел ли из строя узел, в результате, возможно, что на неработающий узел будут посылаться запросы, т. е. алгоритм не обладает отказоустойчивостью;
- никакие затратные по времени операции не производятся в балансировщике;
- различия в технических характеристиках узлов не учитываются, что может привести к неравномерному распределению нагрузки.

Алгоритм взвешенного циклического перебора

Алгоритм взвешенного циклического перебора (англ. Weighted Round Robin) представляет собой модификацию алгоритма равномерного распределения, в которой каждому узлу вручную назначается некоторый параметр, называемый весом, с помощью которого можно варьировать количество запросов, отправляемых на конкретный узел [10].

Алгоритм взвешенного циклического перебора работает по общему принципу, за исключением того, что в массиве *nodes* каждый *i*-й узел повторяется w_i раз, где w_i — вес, назначенный этому узлу.

Особенности алгоритма взвешенного циклического перебора:

- алгоритм прогнозируемый;
- алгоритм не отказоустойчивый, поскольку невозможно отследить вышел ли из строя некоторый узел, при этом, если вышел из строя узел с самым высоким весом, то на него все еще будет посылаться большее число запросов;
- благодаря весам, возможно осуществить настройку алгоритма таким образом, чтобы он учитывал различия в технических характеристиках узлов.

1.4 Динамическая балансировка

Динамическая балансировка — это метод распределения нагрузки на узлы, который предусматривает перераспределение вычислительной нагрузки во время работы, т. е. динамическое обновление расписания [16].

Особенностью динамических алгоритмов балансировки является необходимость в постоянном обмене актуальной информацией об узлах. Простой способ периодического децентрализованного обмена информацией о состоянии заключается в том, что каждый узел периодически отправляет свое текущее состояние всем другим узлам [14].

К динамическим алгоритмам относят [14; 21; 22]

- алгоритм динамического циклического перебора (англ. Dynamic Round Robin);
- алгоритмы наименьших соединений (англ. Least Connections);
- алгоритм наименьшего времени ответа (англ. Least Response Time);
- алгоритм фиксированных весов (англ. Fixed Weighting);
- алгоритм 2 (N) случайных выборов (англ. Random 2 (N) choices);
- алгоритм на основе ресурсов (англ. Resource based).

1.4.1 Алгоритм динамического циклического перебора

Алгоритм динамического циклического перебора работает по принципу взвешенного циклического перебора, за исключением того, что в динамическом алгоритме циклического перебора происходит обновление весов на основании текущих характеристик узлов [14; 17].

Алгоритм может исключать недоступные узлы, перенаправляя задачи на доступные узлы, что позволяет избежать проблем при работе с неисправными узлами. В алгоритме динамического циклического перебора на расписание могут влиять следующие характеристики [1; 10; 21]:

- количество соединений;
- среднее значение загрузки системы за некоторый период времени;
- загрузка процессора узла в текущий момент времени;
- использование памяти узла в текущий момент времени.

Особенности алгоритма динамического циклического перебора:

- алгоритм непрогнозируемый;
- необходимо постоянно собирать информацию об узлах в реальном времени;
- алгоритм отказоустойчивый.

1.4.2 Алгоритмы наименьших соединений

Алгоритм наименьших соединений распределяет нагрузку между узлами, в зависимости от количества активных соединений, обслуживаемых каждым узлом. Узел с наименьшим числом соединений будет обрабатывать следующий запрос, а узлы с большим числом соединений будут перераспределять свою нагрузку на узлы с меньшей загрузкой [23].

Алгоритмы наименьших соединений работают по общему принципу. Если имеется N запросов, M узлов и характеристики узлов хранятся в массиве *parameters*, то алгоритм состоит из следующих шагов:

- 1) сформировать массив, содержащий узлы;
- 2) установить указатель *target* на первый узел;
- 3) пройтись циклом по всем узлам массива, кроме первого:
 - если значение *parameters* для текущего узла меньше значения *parameters* для узла *target*, то установить *target* на текущий узел;
- 4) отправить запрос на узел *target*.

В классической реализации алгоритма наименьших соединений, массив *parameters* содержит количество активных соединений для каждого узла.

Особенности алгоритма наименьших соединений:

- алгоритм непрогнозируемый;
- алгоритм отказоустойчивый, поскольку постоянно собирается информация об узлах, и, в случае отказа, система перераспределит ресурсы;

- необходимо постоянно собирать информацию об узлах в реальном времени;
- балансировщику нагрузки необходимо время, чтобы правильно перенаправить задачу.

Алгоритм взвешенных наименьших соединений

Данный алгоритм комбинирует принципы алгоритма наименьших соединений и алгоритма взвешенного циклического перебора [10]. Он учитывает как веса узлов, так и количество активных соединений. Алгоритм работает по общему принципу алгоритмов наименьших соединений. Для i -го узла значение массива $parameters[i]$ равно отношению количества активных подключений к заданному весу [22].

Особенности алгоритма взвешенных наименьших соединений:

- алгоритм непрогнозируемый;
- алгоритм отказоустойчивый;
- необходимо постоянно собирать информацию об узлах в реальном времени;
- благодаря весам, возможно осуществить настройку алгоритма таким образом, чтобы он учитывал различия в технических характеристиках узлов.

1.4.3 Алгоритм наименьшего времени ответа

Данный алгоритм имеет схожесть с алгоритмом наименьших соединений, только при распределении нагрузки он руководствуется наименьшим временем ответа узла. При выборе учитывается производительность узлов и балансировщик стремится направить запрос к наиболее подходящему узлу [18].

Если имеется N запросов, M узлов и для каждого узла есть время ответа на предыдущий запрос $time$, то алгоритм состоит из следующих шагов:

- 1) сформировать массив, содержащий узлы;
- 2) установить указатель $target$ на первый узел;

- 3) пройтись циклом по всем узлам массива, кроме первого:
 - если $time$ текущего узла меньше $time$ узла $target$, то установить $target$ на текущий узел;
- 4) отправить запрос на узел $target$.

Особенности алгоритма наименьшего времени ответа:

- алгоритм непрогнозируемый;
- алгоритм отказоустойчивый;
- необходимо постоянно собирать информацию об узлах в реальном времени;
- если время ответа каждого узла одинаково, то алгоритм следует выбору по правилам алгоритма циклического перебора.

1.4.4 Алгоритм фиксированных весов

В алгоритме фиксированных весов, администратор назначает каждому узлу вес, после чего все запросы будут приходить на узел с максимальным весом [20]. Если узел перестает справляться с нагрузкой, запросы начинают перенаправляться на узел, с весом меньше.

Если имеется M узлов, записанных в массив $nodes$ и $weights$ — массив весов, назначенных администратором, то алгоритм для каждого приходящего запроса состоит из следующих шагов:

- 1) записать в w максимальное значение $weights$;
- 2) $request_sent_flag = 0$;
- 3) пока $request_sent_flag = 0$ и $w > 0$:
 - записать в $node$ узел, вес которого равен w ;
 - если узел $node$ может принять запрос то, перенаправить запрос узлу $node$, установить значение $request_sent_flag = 1$;
 - иначе, $w = w - 1$.

Таким образом, если имеется запрос r , узел l , момент времени t , функция расписания s , и выполняется равенство $s(l, t) = r$ то, l — узел с наибольшим весом, доступный в момент времени t .

Особенности алгоритма фиксированных весов:

- алгоритм гарантирует, что все запросы будут направляться на доступный в текущий момент времени узел с максимальным весом;
- алгоритм непрогнозируемый;
- алгоритм отказоустойчивый;
- веса узлов назначаются вручную;
- вес узла не меняется в процессе работы.

1.4.5 Алгоритм 2 (N) случайных выборов

Алгоритм 2 (N) случайных выборов — алгоритм, при котором определяется нагрузка $N \geq 2$ серверов, выбранных случайным образом, и запрос отправляется на наименее загруженный из них. В случае $N = 2$ максимальная нагрузка на n серверов с большой вероятностью составит $\Theta(\log \log n)$ [24].

Данный метод может быть использован, когда запрос требуется отправить на наименее загруженный сервер, однако, полная информация о загрузке всех серверов может оказаться дорогостоящей для получения [24].

Альтернативный подход при котором информация о загрузке серверов не требуется, заключается в том, чтобы распределить запрос на случайный сервер. В таком случае максимальная нагрузка на n серверов с высокой вероятностью составит $\Theta(\frac{\log n}{\log \log n})$ [24].

Если имеется K запросов и M узлов, при этом $2 \leq N \leq M$, то алгоритм состоит из следующих шагов:

- 1) сформировать массив *nodes*, содержащий узлы;
- 2) для каждого запроса из K :
 - сформировать массив *randoms*, содержащий N узлов, выбранных случайным образом из массива *nodes*;

- установить переменную *target* на первый доступный узел — *randoms*[0];
- создать переменную $i = 1$;
- пока $i < M$:
 - если нагрузка узла *randoms*[*i*] меньше нагрузки узла *target*, то установить *target* на узел *randoms*[*i*];
 - увеличить значение *i*;
- отправить запрос на узел *target*.

Особенности алгоритма 2 (N) случайных выборов:

- алгоритм анализирует текущую загрузку 2 (N) случайно выбранных узлов перед распределением запросов;
- алгоритм непрогнозируемый;
- алгоритм отказоустойчивый;
- необходимо постоянно собирать информацию о некоторых узлах в реальном времени.

1.4.6 Алгоритм на основе ресурсов

Алгоритм на основе ресурсов — алгоритм, при котором трафик распределяется балансировщиком нагрузки, в зависимости от текущей нагрузки на сервер [18].

Специализированное программное обеспечение, называемое агентом, запускается на каждом сервере и рассчитывает использование ресурсов сервера, таких как его вычислительная мощность и память. Затем агент проверяется балансировщиком нагрузки на наличие достаточного количества свободных ресурсов перед распределением трафика на данный сервер [18].

Если имеется N запросов и M узлов, то алгоритм состоит из следующих шагов:

- 1) сформировать массив *nodes*, содержащий узлы;
- 2) для каждого запроса из N :

- сформировать массив *resources*, содержащий информацию об использовании ресурсов, соответствующим узлом;
- установить переменную *target* на первый доступный узел — *resources[0]*;
- создать переменную $i = 0$;
- пока $i < M$:
 - если узел *resources[i]* обладает достаточным количеством свободных ресурсов для выполнения запроса, то установить *target* на узел *resources[i]* и прекратить выполнение цикла;
 - увеличить значение i ;
- отправить запрос на узел *target*.

Особенности алгоритма на основе ресурсов:

- алгоритм гарантирует, что все запросы будут направляться на узлы, располагающие достаточным количеством свободных ресурсов для их обработки;
- алгоритм непрогнозируемый;
- алгоритм отказоустойчивый;
- необходимо постоянно собирать информацию о всех узлах в реальном времени;
- на каждом узле работает специализированное программное обеспечение, называемое агентом, которое рассчитывает текущее использование ресурсов.

ЗАКЛЮЧЕНИЕ

В процессе выполнения данной научно-исследовательской работы была описана предметная область балансировки нагрузки, формализована задача балансировки нагрузки, а также были:

- описаны основные подходы к решению задачи балансировки нагрузки;
- сформулированы критерии сравнения методов решения задачи балансировки нагрузки;
- классифицированы методы решения задачи балансировки нагрузки.

Таким образом, все задачи для достижения цели данной научно-исследовательской работы были решены, и цель работы была достигнута.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Шуляк А. Сравнительный анализ алгоритмов балансировки нагрузки в среде облачных вычислений // Научный журнал. — 2021. — № 6.
2. Hash Tables [Электронный ресурс]. — Режим доступа: <https://brilliant.org/wiki/hash-tables/> (дата обращения: 07.11.2023).
3. Understanding NAT type on PC [Электронный ресурс]. — Режим доступа: <https://www.ubisoft.com/en-us/help/connectivity-and-performance/article/understanding-nat-type-on-pc/000096222> (дата обращения: 04.01.2024).
4. What is an IP Address — Definition and Explanation [Электронный ресурс]. — Режим доступа: <https://www.kaspersky.com/resource-center/definitions/what-is-an-ip-address> (дата обращения: 09.01.2024).
5. Что такое URL-адрес? [Электронный ресурс]. — Режим доступа: https://developer.mozilla.org/ru/docs/Learn/Common_questions/Web_mechanics/What_is_a_URL (дата обращения: 09.01.2024).
6. Onay Dogan B., Camdereli M. Digital Communication Activities of Corporations in the Context of Corporate Communication and Governance // Online Journal of Communication and Media Technologies. — 2015. — С. 61—77.
7. Digital 2023: Global Overview Report [Электронный ресурс]. — Режим доступа: <https://datareportal.com/reports/digital-2023-global-overview-report> (дата обращения: 07.11.2023).
8. Бершадский А. М., Курилов Л. С., Финогеев А. Г. Исследование стратегий балансировки нагрузки в системах распределенной обработки данных // Известия вузов. Поволжский регион. Технические науки. — 2009. — № 4.
9. Бершадский А. М., Курилов Л. С., Финогеев А. Г. Разработка системы балансировки нагрузки // Гаудеамус. — 2012. — № 20.
10. Павликов М. К. Алгоритм распределения нагрузки в программной системе, построенной на основе протокола NDP // Вестн. Том. гос. ун-та. Управление, вычислительная техника и информатика. — 2017. — № 40.

11. *Асадова Шабнам Рахман К.* Руководство по динамической балансировке нагрузки в распределенных компьютерных системах // ELS. — 2023.
12. *Макаров Д. А., Шибанова А. Д.* Масштабирование веб-приложений // Теория и практика современной науки. — 2021. — № 1.
13. *Гусев А. О., Костылева В. В., Разин И. Б.* Сравнение алгоритмов балансировки нагрузки // Инновационное развитие техники и технологий в промышленности (ИНТЕКС-2020). — 2020. — № 1.
14. *Симаков Д. В.* Управление трафиком в сети с высокой динамикой метрик сетевых маршрутов // Вестник евразийской науки. — 2016. — № 1.
15. *Кхаинг М. Т., Лупин С.* Сравнительный анализ методов оценки производительности узлов в распределенных системах // International Journal of Open Information Technologies. — 2023. — № 6.
16. Балансировка нагрузки в распределенных системах [Электронный ресурс]. — Режим доступа: <https://intuit.ru/studies/courses/1146/238/lecture/6153?ysclid=lr4rglhejo908154193> (дата обращения: 04.01.2024).
17. What Is Load Balancing? [Электронный ресурс]. — Режим доступа: <https://www.nginx.com/resources/glossary/load-balancing> (дата обращения: 12.11.2023).
18. Amazon Web Services [Электронный ресурс]. — Режим доступа: <https://aws.amazon.com/what-is/load-balancing> (дата обращения: 12.11.2023).
19. *Ramirez N.* Load Balancing with HAProxy: Open-Source Technology for Better Scalability, Redundancy and Availability in Your IT Infrastructure //. — Nick Ramirez, 2016. — С. 172. — ISBN 9781519073846.
20. Load Balancing Algorithms and Techniques [Электронный ресурс]. — Режим доступа: <https://kemptechnologies.com/load-balancer/load-balancing-algorithms-techniques> (дата обращения: 04.01.2024).
21. *Haroon M.* Dynamic Load balancing by Round Robin and Warshall Algorithm in Cloud Computing // International Journal of Innovative Technology and Exploring Engineering. — 2021. — № 62.

22. *Gurasis S., Kamalpreet K.* An Improved Weighted Least Connection Scheduling Algorithm for Load Balancing in Web Cluster Systems // IRJET. — 2018. — № 5.
23. *Husain N., Timotius W.* Analisis Algoritma Round Robin, Least Connection, Dan Ratio Pada Load Balancing Menggunakan Opnet Modeler // Informatika: Jurnal Teknologi Komputer dan Informatika. — 2016. — T. 12, № 1.
24. *Richa A., Mitzenmacher M., Sitaraman R.* The Power of Two Random Choices: A Survey of Techniques and Results. — 2000.